

2025 年度 卒業論文

決算データを用いた LSTM による株価
予測手法の開発

目次

1. 研究の目的と結果.....	2
1.1. 研究の目的	2
1.2. 研究の結果	2
2. 問題の定義と既存の手	3
2.1. 専門用語の説明	3
2.2. LSTM [7].....	3
3. 提案手法	4
3.1. 決算データと LSTM を用いた週次株価予測.....	4
4. 結果	5
4.1. 使用するデータセット.....	5
4.2. 予測モデル	6
4.3. 比較指標.....	6
5. 考察および結論.....	10
5.1. 考察.....	10
5.2. 結論.....	10
参考文献.....	11

1. 研究の目的と結果

1.1. 研究の目的

2019 年に話題となった老後資金問題や 2024 年の少額投資非課税制度の緩和などを受け、投資による資産形成は一層の注目を集めている。さらに、近年の AI ブームに影響され、株価予測を中心とした金融に関連する研究が盛んに行われている。株価に関連する研究として、長期にわたる日足データと LSTM を用いた株価予測手法[1]、BERT を用いて経済新聞のテキストから市場のセンチメントを分析する手法[2]が提案されている。また、GAN を用いてデータ拡張を行い、様々な市場に適合できる時系列データを生成する手法[3]が提案されている。

本研究では、四半期毎の決算データを用いたファンダメンタルズ分析による株価予測モデルの開発を行うことを目的とする。決算書類を代表とするファンダメンタルズを用いた株価予測には、様々な知識と豊富な投資経験が求められる。こうした知識や経験を根拠とする意思決定を人工知能に負担させることで、今後新たに増加すると予想される投資家の意思決定に貢献することが期待できる。本研究と同様にファンダメンタルズを利用した研究として、クロスセクショナルな資産構成に対して適切なファンダメンタルズを決定し、マーケットポートフォリオに対してアウトパフォームするか否かを二値分類する研究[4]、企業の持続可能性に係る指標である ESG を用いた株価予測手法[5]などが行われている。また、会計利益とその構成要素である発生項目及び営業キャッシュフローが有する一期先会計利益に関するインプリケーションを Mishkin テストによって調査する研究[6]によると、1980 年から 2000 年の長期間のうちの部分期間について、市場は会計利益や発生項目及び営業キャッシュフローの持続性に対して過大評価及び過小評価していたことがわかった。このことから長期的に効率性が弱度の市場において、先に挙げたようなファンダメンタルズ分析により一定のリターンを得ることは十分可能であるといえる。

1.2. 研究の結果

本研究では、株価データと決算データを併用し、銘柄ごとに訓練した LSTM によって週次の株価リターンの上昇と下落を分類する能力にどのような変化が得られるのかを実験した。その結果、週次の時系列データに決算データを加えるだけでは大きな差を得られないことが分かった。しかし、Precision には統計的に有意な差を得ることができた。

2. 問題の定義と既存の手法

2.1. 専門用語の説明

本節では、最初に株式取引に関する専門用語を説明する。株式商品の売買が成立することを約定と呼ぶ。指定の時間足で区切られた期間内で最初に約定したときの株価を始値(open)、最後に約定したときの株価を終値(close)と呼ぶ。また期間内の最高値と最低値をそれぞれ高値(high)、安値(low)と呼び、上記の4つをひとまとめたものを OHLC データと呼ぶ。

次に決算について説明する。四半期ごとに企業が発表する損益や財産の状態を発表する手続きを決算という、代表的なファンダメンタルズであり、投資をする上で重要なデータが多分に含まれるため、多くの投資家が投資判断に利用する。

テクニカル分析は、株価チャートの情報を利用して再現性の高い指標を組み合わせて株価の変動を分析する手法であり、使用される指標はテクニカル指標と呼ばれる。ベータ値は市場と比較した時の該当銘柄のリスクを値動きのばらつき具合、ボラティリティは指定期間の該当銘柄がもつ値動きのばらつき具合を意味する。

2.2. LSTM [7]

LSTM [7]はセルと呼ばれる単位で構成される RNN の一種である。各セルはゲートと呼ばれるシグモイド層を持つ。各セルは、前のセルから伝達されるセル状態 C_{t-1} と出力 h_{t-1} に対して数値計算を行い、次のセルへ C_t と h_t を伝達する。ゲートは忘却ゲート σ_f 、入力ゲート σ_i 、出力ゲート σ_o の3つあり、それぞれの役割は異なる。各ゲートは誤差逆伝播によって重み W_f, W_i, W_o とバイアス b_f, b_i, b_o を更新する。通常の RNN との違いとして、長期的な依存性を学習できる点が挙げられる。この違いを生むのはゲートの有無であり、各ゲートの作用によって情報の削除・追加が可能となったためである。

忘却ゲート σ_f では、 C_{t-1} の中から削除する情報を、式(1.1)によって得られた f_t によって判定する。入力ゲート σ_i では、 C_{t-1} の数値列の何を更新するのかを判定する。 C_{t-1} を更新するベクトル i_t が式(1.2)によって決定する。同時に C_t が式(1.4)によって決定する。出力ゲート σ_o では、最終的に何を出力するのかを式(1.3)によって判定する。同時に h_t が式(1.5)によって決定する。

$$f_t = \sigma_f(W_f \cdot [h_{t-1}, x_t] + b_f) \quad (1.1)$$

$$i_t = \sigma_i(W_i \cdot [h_{t-1}, x_t] + b_i) * \tanh(W_C \cdot [h_{t-1}, x_t] + b_C) \quad (1.2)$$

$$o_t = \sigma_o(W_o \cdot [h_{t-1}, x_t] + b_o) \quad (1.3)$$

$$C_t = f_t * C_{t-1} + i_t \quad (1.4)$$

$$h_t = o_t * \tanh(C_t) \quad (1.5)$$

3. 提案手法

3.1. 決算データと LSTM を用いた週次株価予測

週足の株価データと決算データを組み合わせて株価予測を行う LSTM を構築する。欠損値は、最後に出現した各データを前方参照することで補完する。このように設定した理由として、投資家が決算データを直接見ることは不可能であること、期間中には発行体が様々な経済活動を行うことから各値を見積もることは不可能であることが挙げられる。また、仮にそれらがニュースや新聞等のテキスト情報から予測モデルを用いておおよそ見積もることができたとしても、ほとんどの投資家が同じ情報を手に入れないことから、株価への影響はほとんどないと考えられる。また時系列データを低頻度に設定したのは、決算データの粒度を高めるためである。

提案手法で構築するネットワークをエラー! 参照元が見つかりません。に示す。また、LSTM 内の各パラメータは 2.2 で示した各式に対応する。入力される各特徴量 x_T は正規化されており、出力される y_T はシグモイド関数によって翌週リターンが上昇する確率を示す。したがって、目的変数が 0.5 より大きいと予測された場合は、予測モデルが翌週リターンの上昇を予測していることとする。




図 1: 提案手法で構築する LSTM ネットワーク

4. 結果

4.1. 使用するデータセット

本研究では、表 1 に示すような条件の下でデータを収集した。東京証券取引所で閲覧可能な東京証券取引所日報[8]から上場廃止銘柄を含む 5402 銘柄のうち、受益証券や投資信託、後述する NEEDS-FinancialQUEST [9]においてヒットしない、十分なデータ量がない等の銘柄を除き、かつ訓練期間の説明変数に不均衡がなかった 88 銘柄について、2001 年 1 月 1 日から 2023 年 12 月 31 日までの前場と後場の OHLC の時系列データを取得した。これに加え、NEEDS-FinancialQUEST から財務三表の四半期毎のデータを取得した。取得・加工したデータのうち、利用するデータを表 2 に示す。

決算データから抽出した 10 個の特徴量は、財務三表を代表する科目のうち、互いに相関係数が低く、特徴量が持つ意味が重複しないように選択した。例えば、流動資産や固定資産といった科目は貸借対照表において重要であると考えられるが、学習には用いず排除した。なぜなら、流動負債や固定負債と強い相関を示したことに加え、企業の負債という財務的側面を表している流動負債や固定負債の方が、企業の潜在的な特性をより強く含むと考えたためである。

目的変数である *return* は、0 より大きい場合に 1 を、0 未満の場合に 0 をクラスとして設定し、評価指標の計算に用いることとする。

表 1: 使用したデータの取得元と期間および銘柄数

内容	決算データ	株価データ
データベース	NEEDs-FinancialQUEST	東京証券取引所日報
期間長	2001 年 1 月 1 日～2023 年 12 月 31 日	
銘柄数	88 銘柄	

表 2: 予測モデルに使用する特徴量

内容	説明変数	内容	説明変数
決算データ	流動負債	株価データ	発行済株式数
	固定負債		一株あたり配当金
	株主資本		β_{52w}
	売上高		$volatility_{52w}$
	売上総利益		$return_t$
	営業利益		
	当期純利益		
	営業活動による CF		
	投資活動による CF		
	財務活動による CF		
		内容	目的変数
		株価データ	$return_{t+1}$

4.2. 予測モデル

本研究では、LSTM を予測モデルとして採用した。この理由として、多くの株価予測に関する先行研究で用いられているという慣習的な側面がある。モデルの具体的な構成を表 3 に示す。表 3 の Settings にある timestep は LSTM に一度に読み込ませる時間長を表しており、本研究では 15 とした。最適化アルゴリズムとして Adam、損失関数としてバイナリクロスエントロピーを使用した。また、過学習防止のために Dropout 層を使用し、各層で 0.2 を設定した。出力層の活性化関数はシグモイド関数を使用しており、クラス分類のための確率を出力する。

本研究では Early Stopping によって学習を早期に打ち切っている。Settings の epochs は最大エポック数、patience はモデルの精度が改善しない場合に打ち切るための最大試行回数である。また、モデル内の変数はすべて python の float32 オブジェクトであり、数値の精度は float32 に依存する。

表 3: 構築した LSTM の具体的な構成とハイパーパラメータの設定

Layer	unit	rate	activate	Settings	Values
InputLayer				dtype	float32
Masking				batch	10
LSTM	32		tanh	timestep	15
Dropout		0.2		epochs	3000
Dense	16		linear	optimizer	Adam
Dropout		0.2		loss	Binary Cross Entropy
Dense	1		sigmoid	patience	20

4.3. 比較指標

予測値と実測値の誤差比較には Accuracy, Precision, Recall, F1score を用いる。 TP , TN , FP , FN は、それぞれ真陽性、真陰性、偽陽性、偽陰性を表している。

Accuracy は次のように表現され、モデルの単純な正答率を表している。

$$Accuracy = \frac{TP + TN}{TP + FP + FN + TN}$$

Precision は次のように表現され、モデルが陽性と予測したデータのうち、実際にデータが陽性だった割合を表している。1.0 に近いほど良いとされる。

$$Precision = \frac{TP}{TP + FP}$$

Recall は次のように表現され、全陽性データのうち、モデルが陽性であると予測できた割合を表している。1.0 に近いほど良いとされる。

$$Recall = \frac{TP}{TP + FN}$$

F1score は次のように表現され、Precision と Recall の調和平均で表される．1.0 に近いほど良いとされる．

$$F1score = \frac{2 \cdot Precision \cdot Recall}{Precision + Recall}$$

また，本研究では予測結果をもとにロング L ，ショート S ，ロングとショートの両方 LS のポジションで取引をした場合の累積リターン R_L ， R_S ， R_{LS} についても評価する．

R_L は以下で計算され．ポジション L で取引をした場合の最終的な収益率を表す．

$$R_L = \left\{ \prod_t^T (1 + r_t) \right\} - 1 \quad T = \{t \mid \hat{r}_t > 0\}$$

R_S は以下で計算され．ポジション S で取引をした場合の最終的な収益率を表す．

$$R_S = \left\{ \prod_t^T (1 - r_t) \right\} - 1 \quad T = \{t \mid \hat{r}_t < 0\}$$

R_{LS} は以下で計算され．ポジション LS で取引をした場合の最終的な収益率を表す．

$$R_{LS} = \left\{ \prod_t^T (1 + r_t) \right\} - 1 \quad \text{if } r_t < 0 : r_t = -r_t$$

また，各評価指標についてウィルコクソンの符号付き順位検定を実施する．この検定は対応のある 2 標本 t 検定であり，対応のある 2 群の差を検定する．帰無仮説 H_0 と対立仮説 H_1 は次に示す通りである．

H_0 : 変化量の符号付順位平均値は 0 である

H_1 : 変化量の符号付順位平均値は 0 でない




図 2: 予測モデルとベースラインモデルの

(a)Accuracy, (b)Precision, (c)Recall および(d)F1score の箱ひげ図

4.3.1. 2 値分類向けの指標を用いた予測モデルの性能評価

図 2 は 4 指標の箱ひげ図であり、表 4 は各指標の基本統計量を示している。この図から、(a)にほとんど違いがみられないのに対して、他の 3 指標については数値の底上げを達成できたことがわかり、平均値・第一四分位数・中央値が比較手法を上回ったことがわかる。しかし、同 3 指標については比較手法の標準偏差が大きいこともあり、75%の段階で(d)が提案手法を上回った。また、表 5 から(b)が有意水準 5%で帰無仮説を棄却でき、同指標は比較手法より改善した。

表 4: Accuracy, Precision, Recall, F1score の基本統計量

手法	評価指標	mean	std	25%	50%	75%
提案手法	Accuracy	0.5015	1.0068	0.4714	0.5000	0.5447
	Precision	0.4300	0.2038	0.4262	0.4834	0.5455
	Recall	0.4636	0.3231	0.1944	0.4692	0.7080
	F1score	0.4154	0.2347	0.2978	0.4890	0.5695
比較手法	Accuracy	0.5109	0.0971	0.4756	0.5000	0.5455
	Precision	0.3736	0.2639	0.0000	0.4712	0.5364
	Recall	0.4360	0.3935	0.0000	0.4059	0.8396
	F1score	0.3594	0.2817	0.0000	0.4495	0.6095

表 5: 各指標のウィルコクソンの符号付き順位検定の P 値

	Accuracy	Precision	Recall	F1score
p 値	0.8934	0.0466	0.4822	0.0935




図 3: 予測モデルとベースラインモデルの

(a) R_L , (b) R_S , および(c) R_{LS} の外れ値を除外した箱ひげ図

4.3.2. 累積リターンによる予測モデルの性能評価

図 3 では、中央値に大きな違いはみられない。表 6 からわかる通り、50%ラインでは(a)でも 0.1%の差しかなく、手法間で得られるリターンの差に大きな違いは無い。表 6 の平均値を見ると、提案手法の(a)は比較手法より大きいですが、その差は僅か 0.2%であるため効果的であるとはいえず、表 7 の検定においても帰無仮説を棄却することはできなかった。しかし、標準偏差は比較手法の方が大きいため、提案手法は同じリターンをより小さいリスクで得られるという点で、提案手法は効果的である。

表 6: 累積リターンの基本統計量

手法	評価指標	mean	std	25%	50%	75%
提案手法	R_L	0.0898	0.3631	-0.0975	0.0013	0.1729
	R_S	-0.0604	0.2266	-0.2063	-0.0095	0.0380
	R_{LS}	0.0338	0.4904	-0.2207	-0.0423	0.1389
比較手法	R_L	0.0869	0.4461	-0.0275	0.0000	0.1601
	R_S	-0.0622	0.2447	-0.1890	0.0000	0.0242
	R_{LS}	0.0419	0.7014	0.2150	-0.0293	0.1741

表 7: 累積リターンのウィルコクソンの符号付き順位検定の P 値

	R_L	R_S	R_{LS}
p 値	0.6799	0.5923	0.7145

5. 考察および結論

5.1. 考察

手法間で大きな違いが得られなかった原因として、適切な決算データが選択できていなかった可能性が挙げられる。本研究ではその週から見た最新の決算データのみ説明変数として用いたが、数年間分の同四半期データや4期分をまとめて利用することで、より強く企業の特徴を吸収できた可能性がある。

また、市場のセンチメントが株価のトレンドを無視した強い上昇や下降を招く場合、株価データと決算データだけではこの影響を吸収しきれない可能性が考えられる。市場のセンチメントを反映した特徴量を予測モデルに学習させることで、より誤差を小さくできるのでないかと考えている。

さらに、社会の大きな構造転換が原因となっている可能性が考えられる。2000年から2023年にかけては、リーマンショックやコロナ禍といった大きな転換点がいくつか見られる。こうしたイベントの影響を避けるには、ある時点におけるサンプルについて予測するクロスセクショナル分析が有効であると考えられる。

5.2. 結論

2001年から2023年にかけて上場していた88銘柄について週次株価予測モデルを構築して誤差を分析した結果、Precisionにおいて5%の有意水準で帰無仮説を棄却できることが分かった。また、各ポジションによって得られるリターンの差に有意な違いは無かったものの、より小さいリスクで近いリターンを得られることが分かった。

参考文献

- [1] S. Minami, Predicting Equity Price with Corporate Action Events Using LSTM-RNN, J. Math. Finance 8 (2018) 58–63. <https://doi.org/10.4236/jmf.2018.81005>.
- [2] 新津康平, 吉浦紀晃, BERT と LSTM を利用した株価予測, 研究報告数理モデル化と問題解決 (MPS) 2021-MPS-132 (2021) 1–6.
- [3] X. Bai, S. Zhuang, H. Xie, L. Guo, Leveraging Generative Artificial Intelligence for Financial Market Trading Data Management and Prediction, (2024). <https://doi.org/10.20944/preprints202407.0084.v1>.
- [4] D. Wolff, F. Echterling, Stock picking with machine learning, J. Forecast. 43 (2024) 81–102. <https://doi.org/10.1002/for.3021>.
- [5] H. Lee, J.H. Kim, H.S. Jung, Deep-learning-based stock market prediction incorporating ESG sentiment and technical indicators, Sci. Rep. 14 (2024) 10262. <https://doi.org/10.1038/s41598-024-61106-2>.
- [6] 奥村雅史, 93080_397.pdf, 早稲田商学 Waseda Commer. Rev. 397 (2003) 141–158.
- [7] S. Hochreiter, J. Schmidhuber, Long Short-Term Memory, Neural Comput. 9 (1997) 1735–1780. <https://doi.org/10.1162/neco.1997.9.8.1735>.
- [8] 東京証券取引所日報, 日本取引所グループ (n.d.). <https://www.jpx.co.jp/markets/statistics-equities/daily/index.html> (accessed October 22, 2025).
- [9] FinancialQUEST - オンラインで NEEDS データを取得 | 日経 NEEDS, (n.d.). <https://needs.nikkei.co.jp/services/financial-quest/> (accessed October 22, 2025).